

## **RAPPORT TP APMAN**

## Vérificateur Orthographique

Binôme: Mouhamadou SYLLA (syllamou) Corentin TEISSIER (teissico)

| Table des matières:                                      |
|--|
| I°) État du logiciel                                     |
| II°) Justifications des structures utilisées             |
| III°) Tests effectués et Exemples d'exécutions           |
| IV°) Analyse comparative des performances CPU et mémoire |
|  |

## I°) État du logiciel

On a mis en place 3 implémentations de structures de données:

- une séquentielle à l'aide de listes chaînées;
- une table de hachage;
- une structure arborescente avec un arbre préfixe.

L'ensemble des structures implémentées fonctionne. La compilation se fait sans erreurs ni warnings. Valgrind montre qu'il n'y a pas de fuites mémoires.

Le fonctionnement est aussi correct, les mots faux sont bien affichés comme faux et tout mot correct est identifié comme correct.

## II°) Justifications des choix effectués

#### a) Choix de la liste chaînée

Parmi les implémentations qu'il fallait réaliser, on devait en faire une qui réalise une recherche séquentielle. En C, les structures qui permettent ce traitement sont les tableaux et les listes. Étant donné qu'un tableau a une taille inchangable déclarée lors de l'initialisation, on a décidé de mettre en place une liste chaînée.

Le programme de test utilisant cette méthode fonctionne comme suit:

D'abord on crée le dictionnaire: on crée une liste vide, on lit le fichier du dictionnaire FR.txt ligne par ligne à l'aide de fgets (chaque ligne correspond à un mot) et on crée un nouveau maillon pour chaque mot lu (le maillon contient le mot en chaîne de caractères) que l'on ajoute en tête de la liste et non enqueue afin d'éviter de parcourir inutilement la liste.

Une fois celà de fait, on a décidé de ne pas afficher les erreurs directement à la console mais de les afficher avec leurs nombres d'occurrences. Pour celà, on a ajouté un champ nombre d'occurrences à la structure liste et on a créé une nouvelle liste appelée liste\_erreurs qui stocke l'ensemble des erreurs trouvés. Ceci permet non seulement de pouvoir afficher les occurrences des

mots mais ça permet aussi d'éviter de toujours rechercher le mot dans la liste dictionnaire qui est très grande on recherche chaque mot dans la liste d'erreurs qui est "petite". Si le mot est présent dans cette liste, on incrémente juste son nombre. S'il n'y est pas, il y a deux possibilités: soit on ne l'avait pas rencontré, soit c'est un mot correct. On le recherche dans le dictionnaire et on agit en conséquence. Pour le recherche du mot, on récupère les lignes du texte une à une (avec fgets) et on récupère les différents mots de chaque ligne séparés par des séparateurs (avec la fonction strtok). Chaque mot est ensuite recherché dans les structures précisées précédemment grâce à des fonctions implémentées dans nos structures de données.

#### b) Choix de la table de hachage

Comme deuxième implémentation, on a choisi la table de hachage parce que c'est la structure qui est le plus souvent utilisé pour représenter un dictionnaire (les implémentations de dictionnaire dans d'autres langages tels que Python et Java repose même sur le principe de la table de hachage). On a alors pris une fonction de hachage efficace qui permet d'éviter un très grand nombre de collisions tout en évitant que la table soit trop longue. Le fonctionnement de la fonction de test est similaire à celle de la liste chaînée avec l'utilisation d'une autre table de hachage qui stocke les erreurs. La table de hachage, qui stocke le dictionnaire, a été initialisé avec une taille de 100000 qui est environ le tiers de l'ensemble des mots dans le dictionnaire. Cette valeur nous semble être un bon choix étant donné que ce nombre permet d'éviter un nombre trop importants de collisions (3.56 en moyenne) tout en évitant d'utiliser une mémoire trop importante. Pour celle sur les erreurs, on a pris une taille de 200 qui permet aussi d'assurer les points précédemment mentionnés (on aura une moyenne de 15 collisions dans la table des erreurs mais cela n'est pas très important car on effectue beaucoup moins de recherche dans cette table).

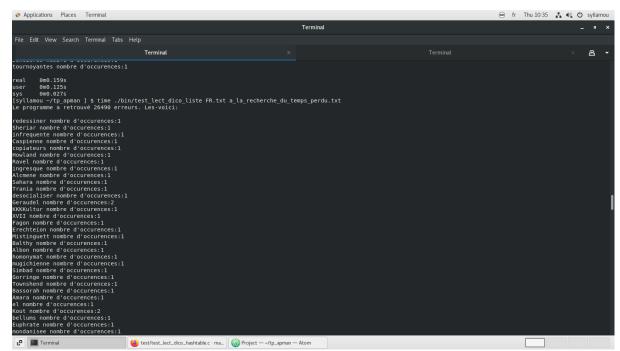
### c) Choix de l'arbre préfixe

Il nous était recommandé de réaliser une implémentation arborescente, on a donc choisi de réaliser l'arbre préfixe qui est aussi bien adapté à la réalisation d'un dictionnaire. Cette fois-ci, on n'a pas repris le même type de fonctionnement que pour les deux précédentes structures. En effet, là où parcourir une plus petite liste ou table de hachage avait un intérêt, il n'y a aucun avantage à parcourir un arbre d'erreurs plutôt que l'arbre du dictionnaire, les deux parcours étant exactement équivalents. On a donc décidé d'afficher les erreurs trouvés directement au niveau de la console.

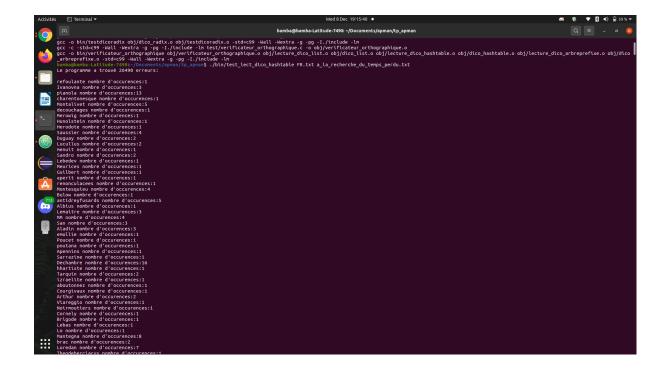
## III°) Tests effectués et exemples d'utilisation

Voici les résultats obtenus lors des différents test réalisés:

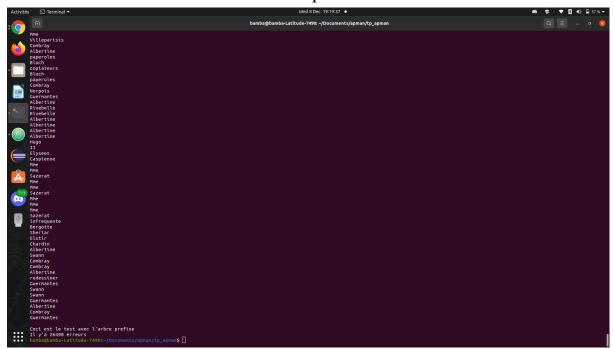
• Le test de la structure de la liste chaînée



• Le test de la structure de la table de hachage



• Le test de la structure de l'arbre préfixe

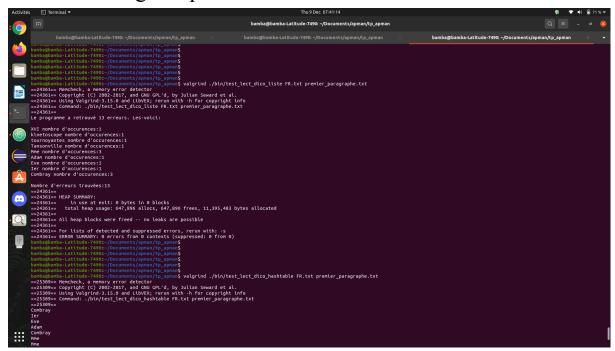


# IV°) Analyse comparatives des performances CPU et mémoire

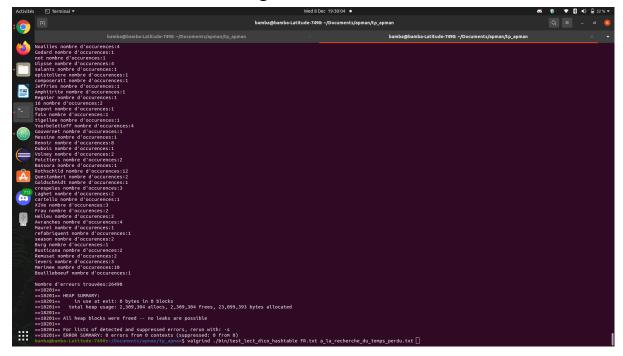
Voici les données renvoyées par l'outil Valgrind concernant la bonne gestion de la mémoire.

#### • Pour la liste chaînée

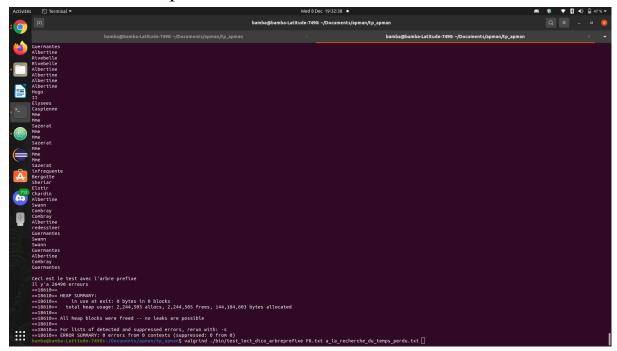
Pour celle-ci on a appelée la fonction sur le premier paragraphe du texte par soucis d'optimisation et en comparaison avec l'appel de la fonction de hachage sur le même paragraphe: celle de la structure chaînée prend 11 395 483 octets de mémoire alors que la table de hachage en prend 16 497 631.



• Pour la table de hachage:



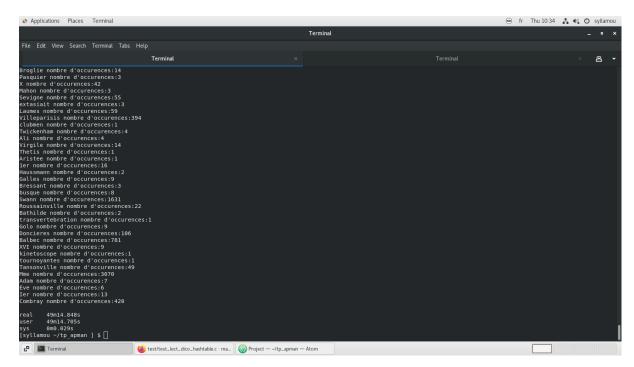
• Pour l'arbre préfixe



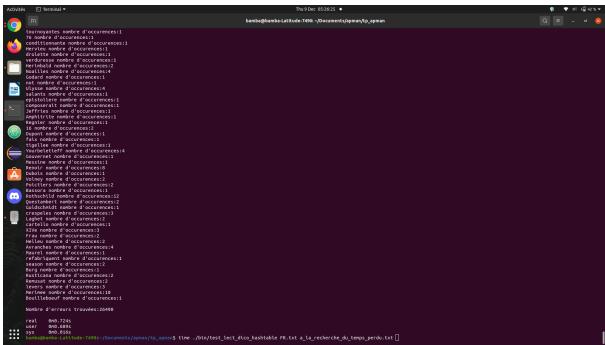
On remarque aussi à travers ces données que l'arbre de préfixe occupe environ 7 fois plus de mémoire que la table de hachage (144 184 603 bytes contre 23 099 393 bytes).

En utilisant la commande time, voici le temps que prend nos différentes structures:

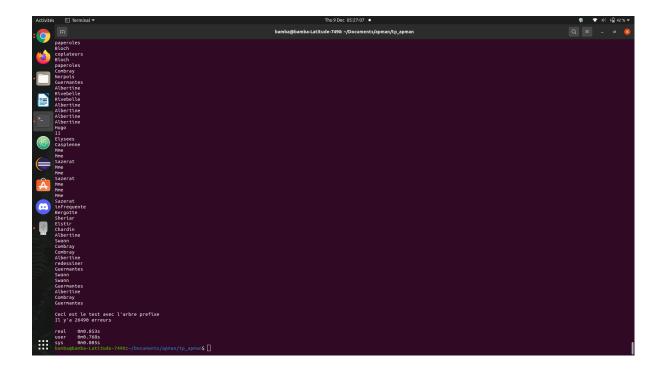
• Liste chaînée



• Table de hachage



Arbre préfixe



Ces résultats sont cohérents et témoignent de la complexité de nos fonctions. En effet, dans la liste chaînée, toute recherche se fait en temps linéaire O(n). Si on néglige les autres opérations (lecture du fichier texte et création du dictionnaire qui restent coûteuses mais le sont moins que la recherche), on se retrouve avec une complexité moyenne de O(N\*N') avec N qui est le nombre de mots dans le texte de vérification et N' le nombre de mots dans le dictionnaire. On se retrouve donc dans la structure de liste chaînée avec une complexité temporelle d'au moins quadratique O(N'2) à la taille du dictionnaire qui est énorme (plus de 300000 mots). La structure liste n'est pas adéquate à ce type d'utilisation, la complexité spatiale n'est pas énorme mais celle temporelle est trop grande pour des fichiers de cette taille.

La structure table de hachage, pour la recherche et l'insertion, à une complexité de O(1+n/k) avec n le nombre de mots dans le dictionnaire et k la taille de la table de hachage. Étant donné que l'on a utilisé une bonne fonction de hachage et que la taille choisie est importante ( ½ de la taille du dictionnaire), notre complexité n'est pas linéaire et la plupart des opérations se fait en temps constant même si à cause des collisions certaines se font en temps linéaire. En prenant en compte l'ensemble des opérations lors du test, on peut dire que cette structure a pour complexité globale O(N) avec N le nombre de mots à vérifier.

Dans la structure de l'arbre préfixe, la recherche et l'insertion de tout mot se fait en O(k) avec k la longueur du mot. On est ainsi assurés que ces opérations se font tout le temps en temps constant ( là où dans la table de hachage certaines de ces opérations sont linéaires). La complexité globale de notre fonction peut donc être prise O(N) avec N nombre de mots à vérifier. En termes de complexité temporelle, l'arbre préfixe est légèrement plus efficace que la table de hachage(dans les captures ajoutées à ce rapport, la table de hachage prend moins de temps grâce à la manière dont on traite les erreurs et les bons choix effectués sur la table de hachage). Mais en termes de mémoire occupée, l'arbre préfixe devient tout de suite moins intéressant. On peut, en effet, considérer que la table de hachage a, comme la liste chaînée, une complexité spatiale de O(n) -la table de hachage occupe une plus grande mémoire que la liste mais la différence n'est pas énorme au vu des choix effectués sur la fonction de hachage et la taille-. Ceci en ne rentrant pas dans les détails quant à la taille qu'occupent les mots en tant que tels mais juste du nombre de mots à stocker. L'arbre préfixe quant à lui utilisent des nœuds et chaque nœud correspond non pas à un mot mais à une lettre d'un mot. Ainsi donc en terme d'espace , on est en moyenne à O(N\*k) avec k le nombre moyen de lettres dans un mot et N le nombre de mots à stocker. Ceci est toujours linéaire mais reste plus important que pour la table de hachage ce qui explique les résultats fournis par le Valgrind le nombre de d'octets utilisé étant 7 fois plus important.

Ainsi donc pour résumer, la liste chaînée est la structure qui utilise le moins la mémoire mais c'est la moins efficace en termes de complexité temporelle qui est quadratique. La table de hachage, quant à elle, occupe un peu plus d'espace que la liste chaînée mais a une bien meilleure complexité temporelle avec un bon temps d'exécution. L'arbre préfixe a lui aussi une bonne complexité temporelle et est la plus rapide de nos 3 structures. Toutefois, elle utilise une quantité de mémoire bien plus importante. Si l'on doit effectuer un compromis niveau temps d'utilisation et mémoire, la table de hachage est la structure qu'il faut utiliser. Si en revanche, on souhaite avoir un temps d'exécution le plus petit possible sans faire attention à la mémoire, il faudra recourir à l'arbre préfixe. Si toutefois, la taille des données à traiter n'est pas énorme et qu'on souhaite utiliser le moins de mémoire possible, la liste chainée est particulièrement adaptée mais elle ne l'est pas sur de gros fichiers tels que des dictionnaires.